Programación básica en Java con Hadoop

Tabla de contenidos

Cómo se ejecuta una aplicación Hadoop

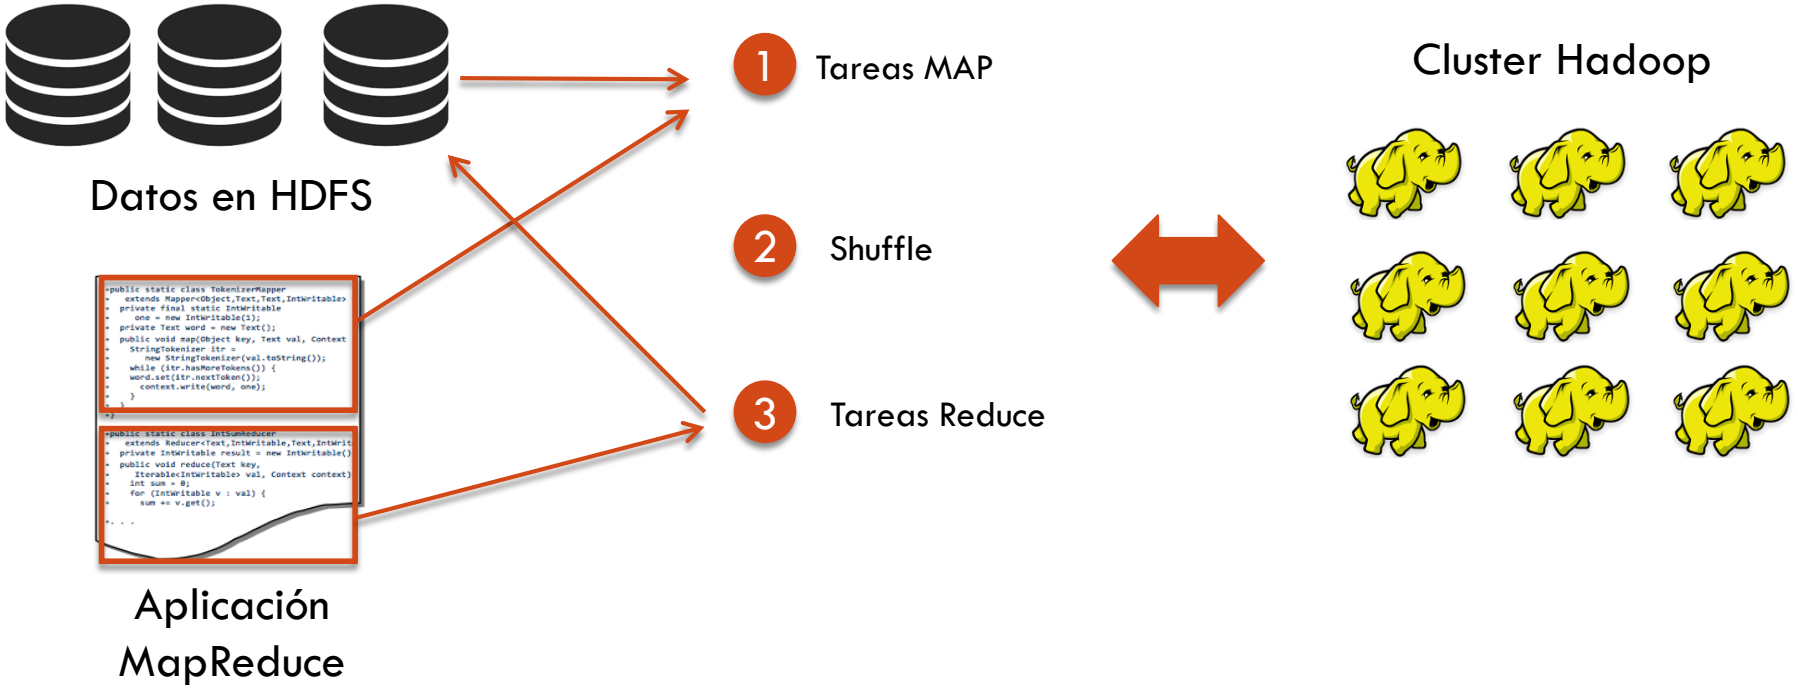

Arquitectura Hadoop

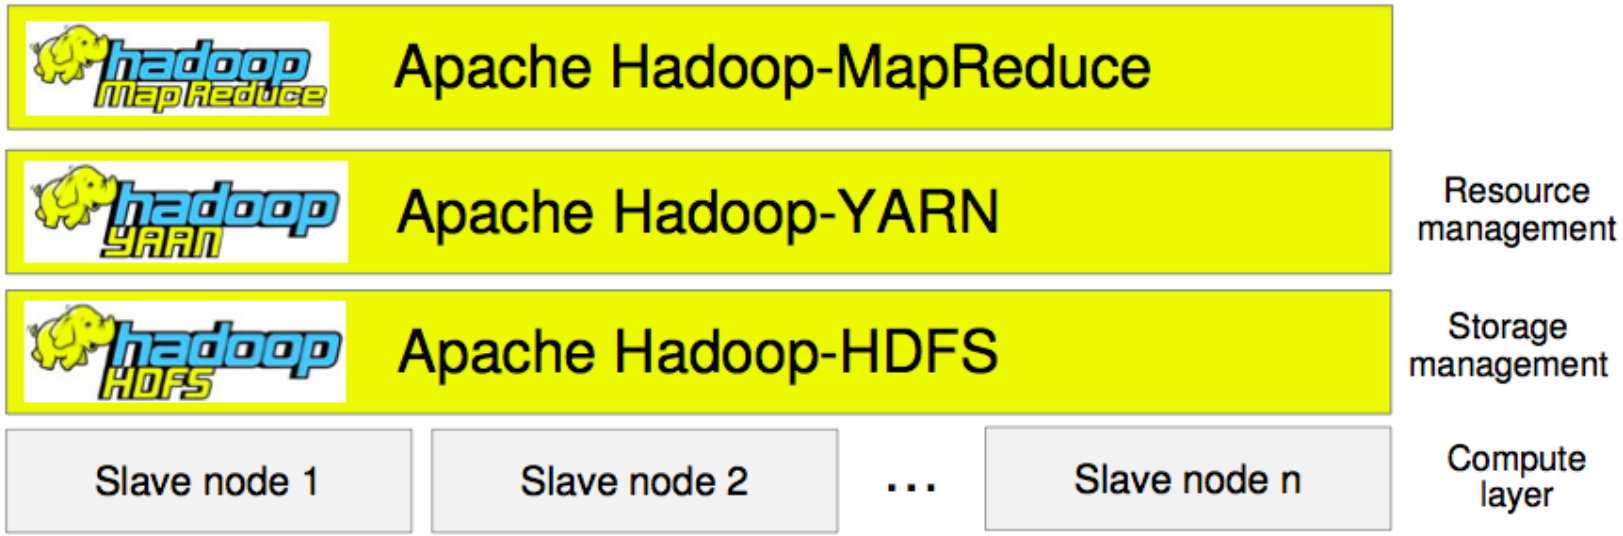

Hadoop es…

- Framework de desarrollo para aplicaciones Big Data
  - Paradigma MapReduce
    - Google™
- Entorno de ejecución
  - Aplicaciones tipo batch
  - Lectura intensiva
- Se encarga de almacenar los datos generados
- Escalable

¿Cómo desarrollar aplicaciones Hadoop?

- **Desarrollos Map/reduce en JAVA**
  - Muy Complejo
- **PIG**
  - Lenguaje Open/Source de más alto nivel
  - Estándar
- **HIVE**
  - Lenguaje Open/Source
  - Similar al SQL
- **JAQL**
  - ✓ Lenguaje similar a PIG, mayor funcionalidad
- **Herramientas tipo BigSheets**
  - ✓Navegador/Hoja de Cálculo
  - ✓No requiere desarrollo


PIG

Difícil

Fácil

Hands on

- Guión de prácticas
  - Conexión y uso de un sistema Hadoop
  - Ejecución de una aplicación de ejemplo: WordCount

El lenguaje de programación Java

- Creado en el año 1991 (oak) por *Sun Microsystems*
- Objetivos de diseño:
  - Lenguaje orientado objetos
  - Máquina virtual de Java
  - Fácil de utilizar
  - Ejecución de código remoto y soporte de red

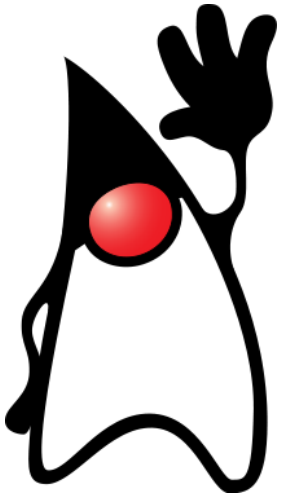

EL lenguaje de programación Java

- Lenguaje orientado a objetos
  - Clases
    - Herencia
    - Interfaces
  - Objetos
  - Métodos
  - Parámetros por referencia
  - Sintaxis

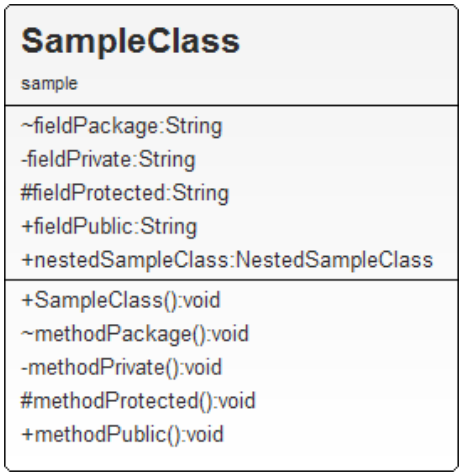

Definición del "tipo de variable" más completa que en otros lenguajes: campos y métodos (y accesibilidad de los mismos).

- ¿Qué operaciones puedes hacerse sobre un objeto?
- ¿Qué campos/atributos definen un objeto?
- ¿Qué métodos y atributos son accesibles y a quién?

static: campos comunes a todos los objetos de una misma clase

EL lenguaje de programación Java

- Lenguaje orientado a objetos
  - Clases
    - Herencia
    - Interfaces
  - Objetos
  - Métodos
  - Parámetros por referencia
  - Sintaxis

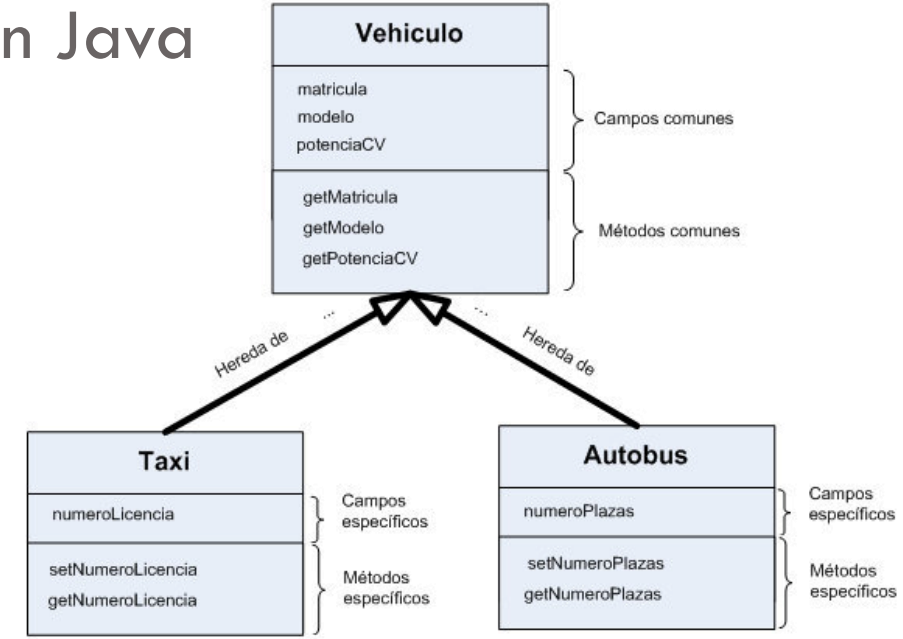

Objetivo: reutilización de código y trabajo.

- Crear nuevas clases con características comunes a clases existentes
  - Los métodos heredados pueden sobreescribirse
- Ahorro de código y trabajo
- Beneficio del testeo y rendimiento de código muy utilizado

Un paso más: clases abstractas

EL lenguaje de programación Java

- Lenguaje orientado a objetos
  - Clases
    - Herencia
    - Interfaces
  - Objetos
  - Métodos
  - Parámetros por referencia
  - Sintaxis

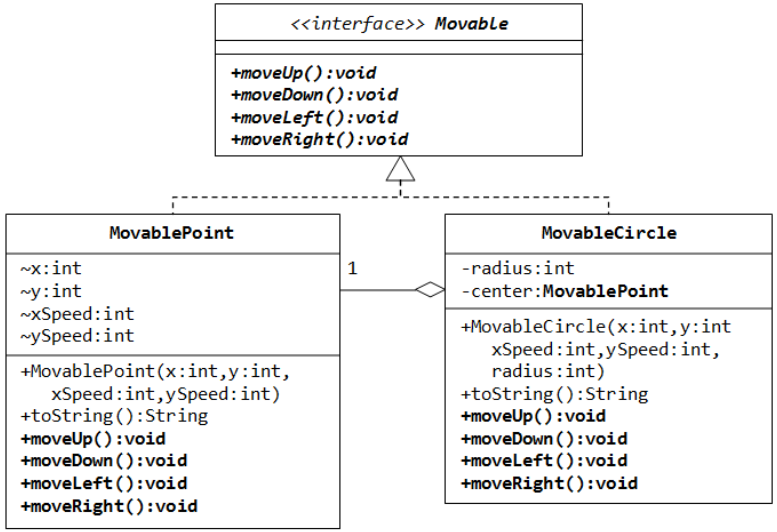

Aproximación de Java para resolver el problema de la herencia múltiple (contemplada en otros lenguajes OO)

- Equivalente a una herencia de una clase abstracta
  - Se fuerza a que las clases que implementan la interfaz implementen los métodos
  - Cada clase lo puede implementar como desee

Ej: interfaz *Serializable*

EL lenguaje de programación Java

- Lenguaje orientado a objetos
  - Clases
    - Herencia
    - Interfaces
  - Objetos
  - Métodos
  - Parámetros por referencia
  - Sintaxis

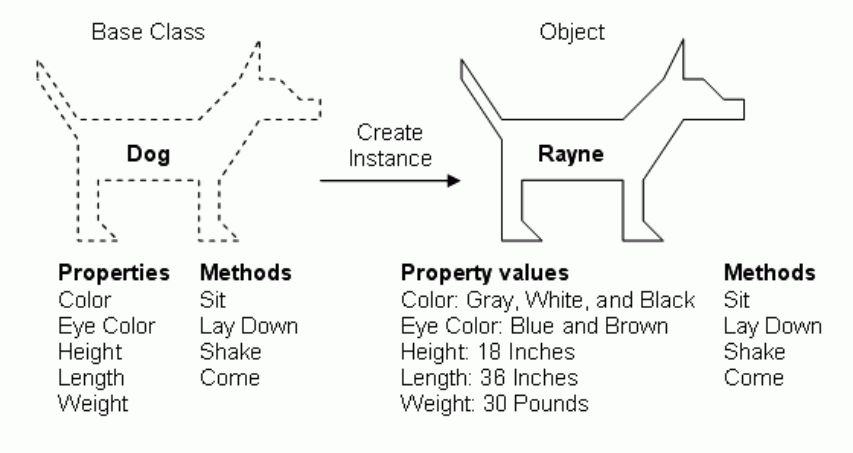

Un objeto es una instancia de una clase. Ocupa tanto como el espacio requerido para almacenar los atributos (asociados a la clase) que identifican al objeto.

EL lenguaje de programación Java

- Lenguaje orientado a objetos
  - Clases
    - Herencia
    - Interfaces
  - Objetos
  - Métodos
  - Parámetros por referencia
  - Sintaxis

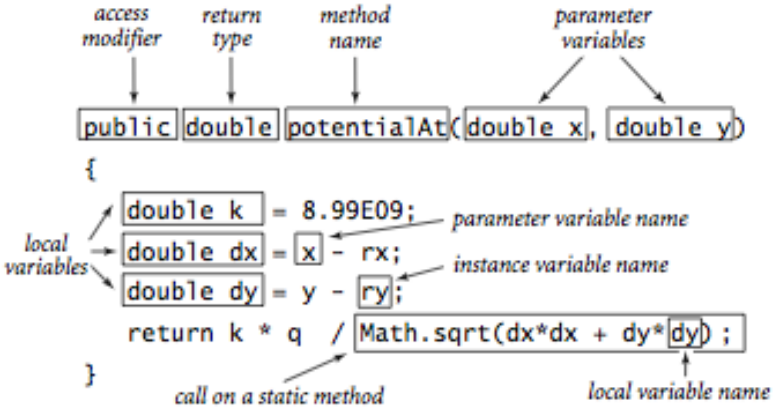

Anatomy of a data-type method

Un método de una clase concreta se caracteriza por su accesibilidad, su nombre, tu tipo de retorno y sus parámetros. En una clase pueden existir métodos diferentes que tengan el mismo nombre, pero que reciban parámetros de diferentes clases.

Accesibilidad: private, protected, public, default

Otros: static (solo acceso a métodos y campos static)

EL lenguaje de programación Java

- Lenguaje orientado a objetos
  - Clases
    - Herencia
    - Interfaces
  - Objetos
  - Métodos
  - Parámetros por referencia
  - Sintaxis

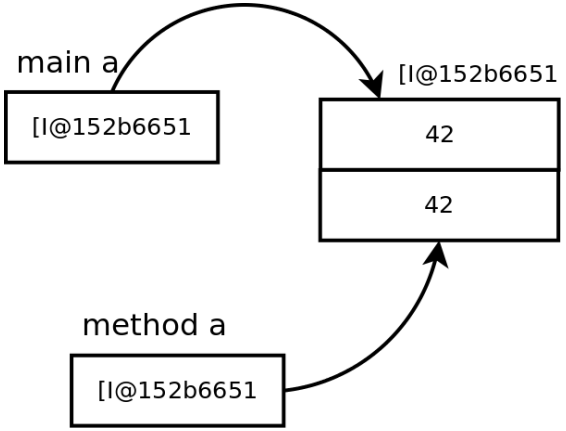

Cada vez que se escribe el nombre un objeto en un programa Java, se utiliza una referencia a la zona de memoria donde está alojado el objeto, y no una copia del mismo.

EL lenguaje de programación Java

- Lenguaje orientado a objetos
  - Clases
    - Herencia
    - Interfaces
  - Objetos
  - Métodos
  - Parámetros por referencia
  - Sintaxis

```
public class ClassName extends SuperClass {
    private static final int CONSTANT= 0;
    /* This comment may span multiple lines. */
    private static int staticField= 0;
    // This comment may span only this line
    private String field= "zero";
    // TASK: refactor
    public int foo(int parameter) {
        abstractMethod();
        int local= 42*hashCode();
        staticMethod();
        return bar(local) + 24;
    }
```

Clases y métodos.
Dentro, sintaxis similar a C.

EL lenguaje de programación Java

- Máquina Virtual de Java (JVM)
  - Portabilidad
    - Cualquier dispositivo
    - Cualquier SO
    - Java > ByteCode > Código ejecutable
  - Menor rendimiento
    - Etapas intermedias de ejecución
    - Dificultad de programación MP/MC
  - Aislamiento

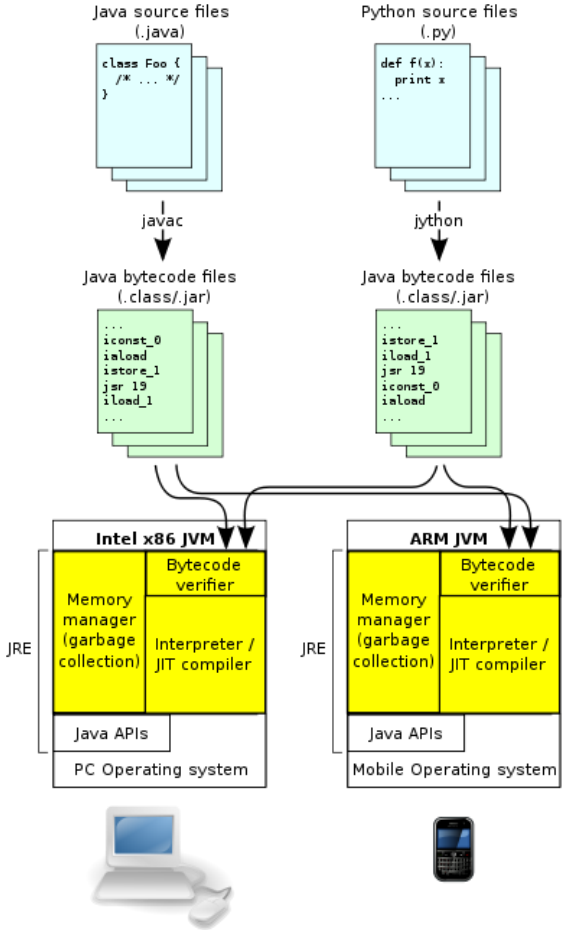

EL lenguaje de programación Java

- Fácil de utilizar
  - La comunidad Java dispone de innumerables paquetes con código listo para su reutilización
    - Java Beans
  - Excepciones
  - Sintaxis similar a C
  - Entornos de programación IDE: NetBeans, Eclipse

- Gestión de memoria
  - Garbage collector
    - El programador no se preocupa de liberar recursos una vez se ha terminado con ellos
    - Se almacena un número de referencias por objeto. Cuando llega a 0, el GC lo liberará la próxima vez que se ejecute

EL lenguaje de programación Java

- Código existente y documentación
  - Mucho código ya implementado
  - Vale la pena buscar si lo que buscas ya existe
  - Documentación: JavaDoc
    - https://docs.oracle.com/javase/7/docs/api/

    - También para Hadoop
      - https://hadoop.apache.org/docs/r2.6.1/api/org/apache/hadoop/mapred/

Caso de ejemplo: WordCount

Descargar ejemplo WordCount de moodle

```
package org.apache.hadoop.examples;

import java.io.IOException;
import java.util.StringTokenizer;

import org.apache.hadoop.conf.Configuration;
import org.apache.hadoop.fs.Path;
import org.apache.hadoop.io.IntWritable;
import org.apache.hadoop.io.Text;
import org.apache.hadoop.mapreduce.Job;
import org.apache.hadoop.mapreduce.Mapper;
import org.apache.hadoop.mapreduce.Reducer;
import org.apache.hadoop.mapreduce.lib.input.FileInputFormat;
import org.apache.hadoop.mapreduce.lib.output.FileOutputFormat;
import org.apache.hadoop.util.GenericOptionsParser;

public class WordCount {

  public static class TokenizerMapper
       extends Mapper<Object, Text, Text, IntWritable>{ ... }

  public static class IntSumReducer
       extends Reducer<Text,IntWritable,Text,IntWritable> { ... }

  public static void main(String[] args) throws Exception { ... }
}
```

Inclusión de paquetes necesarios

Definición de clase Mapper
(herencia de clase)

Definición de clase Reducer

(herencia de clase)

Configuración del entorno MapReduce

Caso de ejemplo: WordCount

```
public static void main(String[] args) throws Exception {
  Configuration conf = new Configuration();
  String[] otherArgs = new GenericOptionsParser(conf, args).getRemainingArgs();
  if (otherArgs.length != 2) {
    System.err.println("Usage: wordcount <in> <out>");
    System.exit(2);
  }
  Job job = new Job(conf, "word count");
  job.setJarByClass(WordCount.class);
  job.setMapperClass(TokenizerMapper.class);
  job.setCombinerClass(IntSumReducer.class);
  job.setReducerClass(IntSumReducer.class);
  job.setOutputKeyClass(Text.class);
  job.setOutputValueClass(IntWritable.class);
  FileInputFormat.addInputPath(job, new Path(otherArgs[0]));
  FileOutputFormat.setOutputPath(job, new Path(otherArgs[1]));
  System.exit(job.waitForCompletion(true) ? 0 : 1);
}
```

<u>Configuración del trabajo MR</u>

- Configuración de parseo de los argumentos de entrada

- Clases Mapper, Combiner y Reducer

- Clases de las claves y valores de salida

- Configuración de los parámetros de entrada y salida

Caso de ejemplo: WordCount

```
public static class TokenizerMapper
     extends Mapper<Object, Text, Text, IntWritable>{

  private final static IntWritable one = new IntWritable(1);
  private Text word = new Text();

  public void map(Object key, Text value, Context context
                  ) throws IOException, InterruptedException {
    StringTokenizer itr = new StringTokenizer(value.toString());
    while (itr.hasMoreTokens()) {
      word.set(itr.nextToken());
      context.write(word, one);
    }
  }
}
```

Separamos palabras de una misma línea, y las procesamos por separado

Clase Mapper

La clase abstracta Mapper de la que hereda, fuerza tipo de argumentos de entrada, y la implementación del método map.

Método map

Entrada:

- Clave (en este caso no utilizada, pero contemplada para MR multi-etapa)
- Valor (cada línea de texto)

Salida:

- Clave (palabra individual)
- Valor (en nuestro caso, 1)

Caso de ejemplo: WordCount

```
public static class IntSumReducer
     extends Reducer<Text,IntWritable,Text,IntWritable> {
  private IntWritable result = new IntWritable();

  public void reduce(Text key, Iterable<IntWritable> values,
                     Context context
                     ) throws IOException, InterruptedException {
    int sum = 0;
    for (IntWritable val : values) {
      sum += val.get();
    }
    result.set(sum);
    context.write(key, result);
  }
}
```

Clase Reducer

La clase abstracta Reducer de la que hereda, fuerza tipo de argumentos de entrada, y la implementación del método reduce.

Método reduce

Entrada: par clave, valor generado en la etapa map

Salida: nuevos pares clave, valor

- clave: la misma que antes
- valor: suma de todos los *valor* asociados a una misma clave.

Caso de ejemplo: WordCount

```
public static class IntSumReducer
     extends Reducer<Text,IntWritable,Text,IntWritable> {
  private IntWritable result = new IntWritable();

  public void reduce(Text key, Iterable<IntWritable> values,
                     Context context
                     ) throws IOException, InterruptedException {
    int sum = 0;
    for (IntWritable val : values) {
      sum += val.get();
    }
    result.set(sum);
    context.write(key, result);
  }
}
```

Clase Combiner

También implementa la interfaz Reducer. Reduce la cantidad de datos que se barajean para reducir movimiento de datos y "facilitar" las cosas al reducer. En este ejemplo las clases coinciden.

Combiner vs Reducer

- Los formatos tanto de entrada como de salida deben coincidir con los de salida del Mapper
- Un Combiner toma sus datos de entrada de un solo Mapper
- Sólo pueden usarse con funciones conmutativas y asociativas (o alterarían el resultado)

Caso de ejemplo: WordCount

- Mapper + Reducer

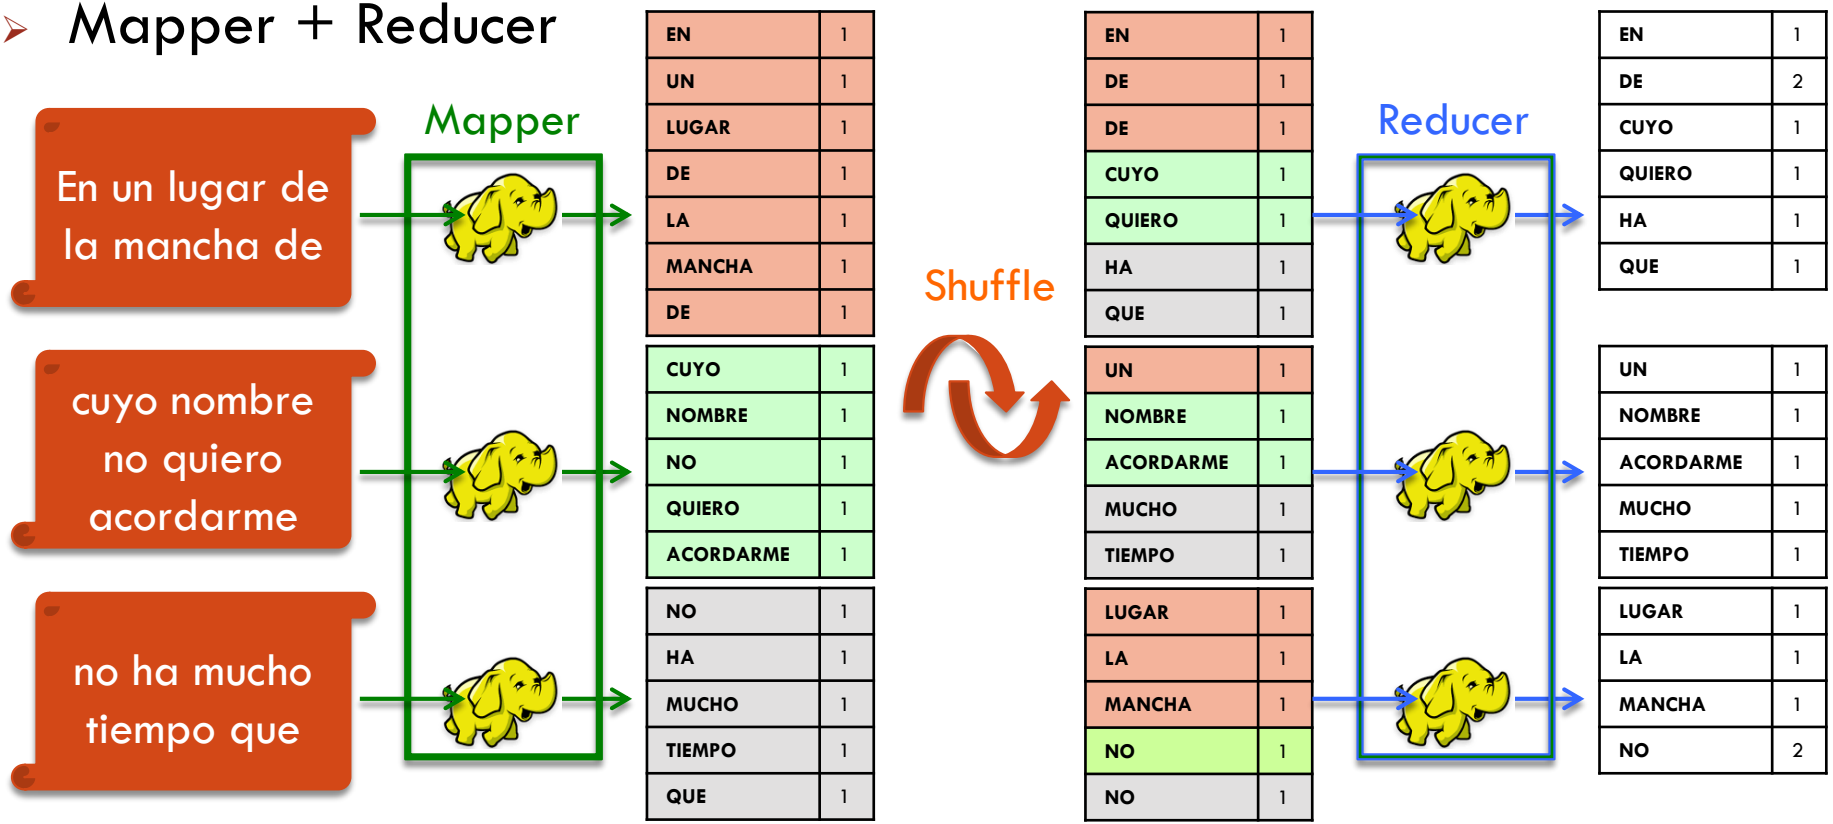

Caso de ejemplo: WordCount

- Con Combiner

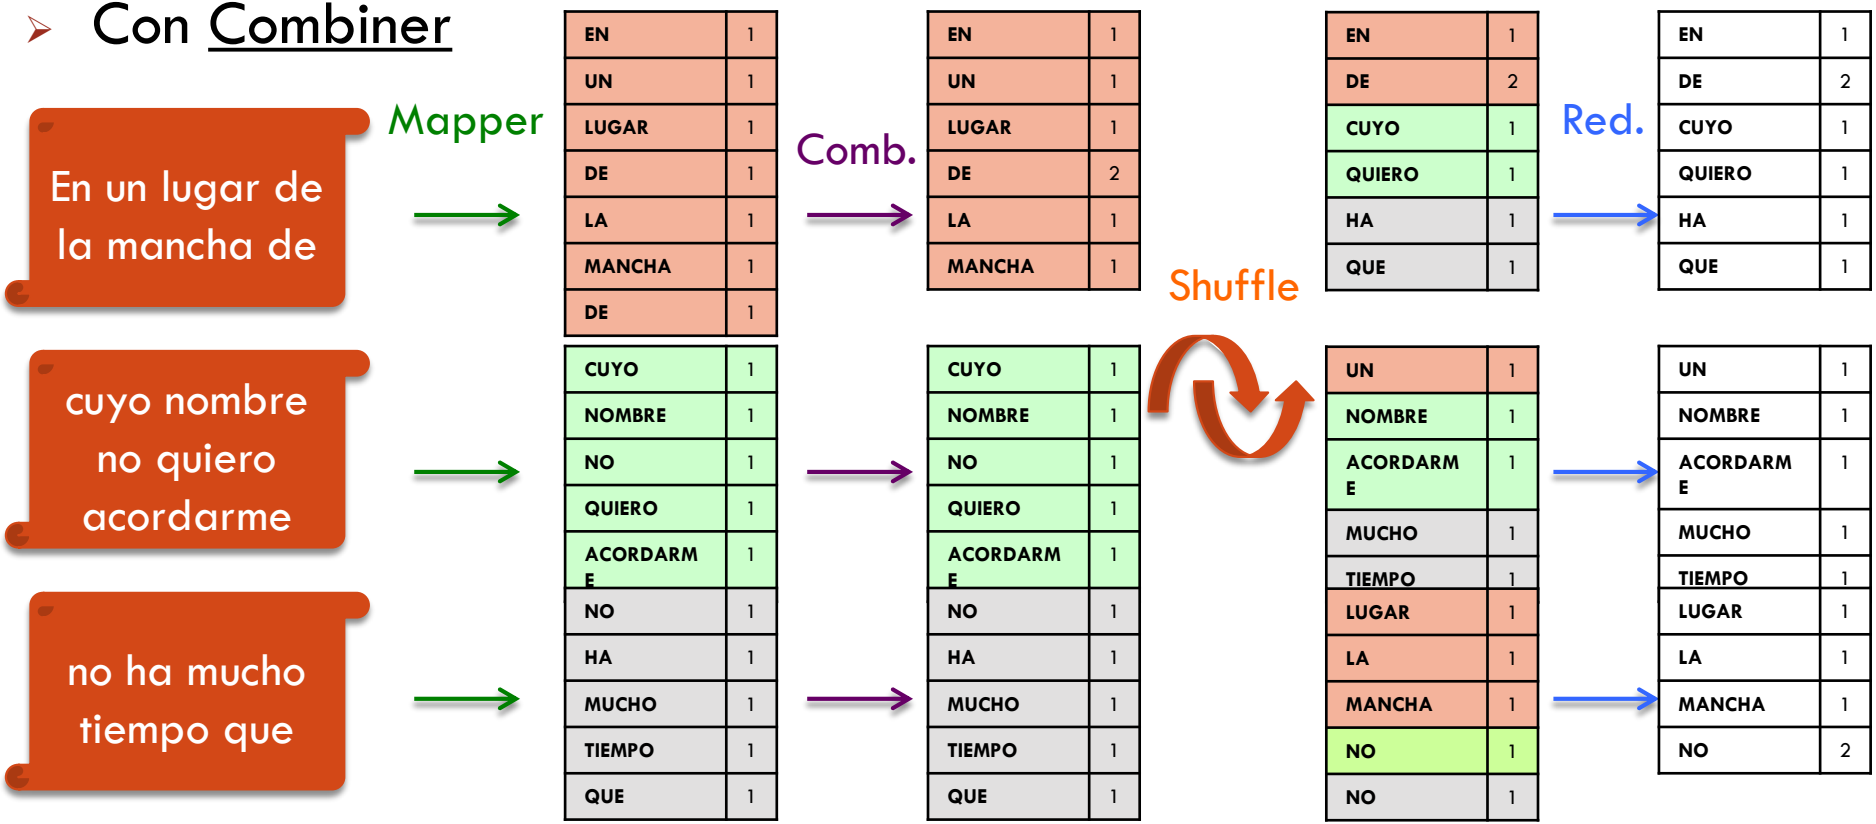

Caso de ejemplo: WordCount

- Ejemplo de salida

(Y	1
(a	1
(al	1
(como	1
(creyendo	1
(de	2
…	
Anoche	1
Anteo,	1
Antequera	1
Antequera.	1
Antequera;	1
Antes	1
…	

Has	2
Haz	1
He	1
Hechas,	2
Hecho	5
Hechos	1
Henares	1
Henares,	1
Hermandad	2
Hermandad,	1
…	
has	21
has,	1
hasme	1
hasta	53
hato	1
hato.	1
hay	52
hay,	2
…	

Ejercicio

- Vamos a modificar el ejemplo de WordCount que hemos tomado como partida, para que no tenga en cuenta signos de puntuación, ni las mayúsculas/minúsculas

- Guión de prácticas
  - Crear una aplicación Hadoop en Java

Instalar entorno JDK de java

- Instalar el entorno de desarrollo java
  - `> yum install java-1.7.0-openjdk-devel.x86_64`
- Comprobar que funciona
  - `> javac -version`
- Compilar ejemplo WordCount en java
  - Descargue de moodle el fichero fuente WorCount.java y coloquelo en el directorio /opt/work
  - Cd /opt/work
  - > javac -classpath /opt/hadoop/share/hadoop/common/*:/opt/hadoop/share/hadoop/mapreduce/* -d WordCount WordCount.java
- Crear Jar
  - jar -cvf WordCount.jar -C WordCount/ .

Instalar entorno JDK de java

- Descarga el fichero quijote.txt de moodle y colóquelo en un directorio de trabajo y vea su contenido
  - Cat /opt/work/quijote.txt

- Ejecución en Hadoop de WordCount
  - > bin/hadoop jar /opt/work/WordCount.jar uam.WordCount /opt/work/quijote.txt /opt/work/salida1

- Revise la salida.

Información adicional

- Parámetros de configuración de una tarea hadoop
  - Al lanzar la tarea:
    - hadoop jar /.../hadoop-examples.jar terasort **–D**mapred.map.tasks=XX **–D**mapred.reduce.tasks=XX terasort-input/ terasort-output/
    - … -Dmapreduce.map.memory.mb=4096 …
  - Desde el código:
    - Job.setNumReduceTasks(int)
  - Configuración por defecto de los servicios hadoop
    - cat /usr/iop/current/hadoop-yarn-client/etc/hadoop/mapred-site.xml
  - https://hadoop.apache.org/docs/current/hadoop-mapreduce-client/hadoop-mapreduce-client-core/MapReduceTutorial.html

Información adicional

- Encadenar trabajos
  - Dependencias entre tareas:
    - x.addDependingJob(y)
    - https://hadoop.apache.org/docs/r2.6.1/api/org/apache/hadoop/mapred/jobcontrol/Job.html
  - https://developer.yahoo.com/hadoop/tutorial/module4.html#chaining