

TEMA 1: Introducción

Def (Rec. biométrico). - Establecer la identidad de una persona basando en atributos físicos o conductuales.

Rasgos

- ↳ Fisiológicos/morfológicos (no se pueden modificar fácilmente; visibles o virtualizables): huella, cara, iris, orejas, retina, ...
- ↳ Fisiológicos/biológicos: ADN, EKG, olor
- ↳ Conductuales: voz, firma, forma de andar, ...

Historia

- Huellas de manos → 31.000 años atrás
- Huellas dactilares → transacciones, marcas personales
- 1870: Bertillon sistema antropométrico: medidas estandarizadas cuerpo.
- 1988: Semi-automático facial recognition.

Autenticación usuarios

- Tradicional: algo que se sabe o se posee (contraseñas, tokens, ...) ↳ FRAUDE
- Biométrico: algo que es o produce (requiere registro)

Características ideales

- Universalidad, unicidad, permanencia, facilidad de recolección
- Poca complejidad: rendimiento, aceptabilidad, facilidad de elección

Identificación vs verificación

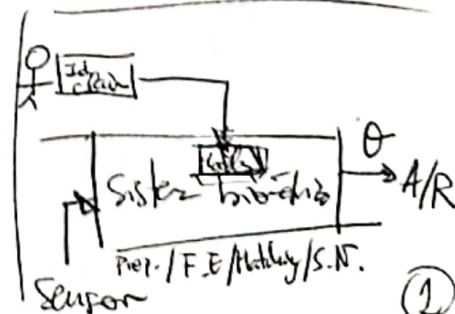
- Identificación: determinar identidad de una persona (no identity claim)

Es one-to-many, coste lineal

- Verificación: comprobar si alguien es quien dice ser. Es one-to-one, coste indep. del nº de usuarios en la BBDD.

↳ Aplicaciones: passport, logins, vigilancia, bancos, medicina, comercio, carnet conducir, ...

Privacidad: datos personales, acceso por terceros, seguridad.



TAREA 2: Métricas

Matriz confusión: visualizar rendimiento de sist. verificación

Valor real		genuine	imposter
	genuine	TP	FN
	imposter	FP	TN

Resultado

- FP: Ocurre cuando la variación inter-clase es baja (diferentes sujetos obtienen scores parecidos).
 ↳ Intencional: ataque
 ↳ No intencional: gemelos, padre e hijo, ...
- FN: Ocurre cuando hay variabilidad intra-clase: la edad, la falta de interoperabilidad del sistema, ...

Métricas


• Accuracy: rendimiento conjunto: $\frac{TP+TN}{TP+TN+FP+FN}$ ($H_b = 1 - acc = error$)

• FAR: $\#FP / \text{all imposter} = \frac{FP}{FP+TN}$ ($FAR = 1 - FRR$)

• FRR: $\#FN / \text{all genuine} = \frac{FN}{TP+FN}$

Threshold


Umbral a partir del cual aceptamos un identity claim (civil = low FN, militar = low FP)




ROC and AUC

curva que ilustra el rendimiento conforme varía el threshold (comparable): TAR vs FAR

DET: FRR vs FAR (EER = equal)



CMC (Identificación): % recognized vs Rank (Rank-n: identificación entre los n primeros)



TEMA 3: Fingerprint

Def. - Mosaico de picos y valles papilares del dedo humano

↳ Tiene mucha información de identificación (única?)

↳ No cambia apenas con el tiempo; quedan bien los distintos

Historia


(rango e histórico)

1888: Galtier publica evidencia científica

1902: Bertillon

1924: FBI

Tipos: Natural, Latente, digital (sensors) ✓; ridged vs plain



Sensors: Capacitivos (placa conductora, epidermis), ópticos (luz, 2D), ultrasonidos (ondas de sonido se penetra la epidermis, 3D), térmicos (diferencia de temperatura ridges y valleys; problema: disipación).

Calidad de imagen (wet, dry, ...) NFIQ (NIST Fingerprint Image Quality)


Detección de ataques: skin vs non-skin (handcrafted + DL features)

Macro-regularities: Whorl (O), loop (U), delta (Δ).

Minutiae / Galtier's char.: terminación o bifurcación de crestas.

Very local: pores, crestas impurezas, ...

Extracción de características



• Segmentación: background (uniform) vs foreground (striped)

• Orientación: ángulo de crestas con el eje horizontal en un vecindario

• Frecuencia: número de crestas por unidad de longitud en un segmento ⊥ orientación.



(2)

- Singularidades (racco) \rightarrow Índice de Poincaré (dividir línea de orientación en subregiones, y sumar).
- Ridge pattern: enhancement + binarización, thinning (1px) (orientación + frecuencia + filtro Gabor)
- Minutize: se eligen puntos de partida, se buscan las crestas más cercanas, y se sigue hasta una bifurcación o terminación. (líneas locales con respecto a la dirección ortogonal a ellas).



crossing number

Todo este proceso se puede hacer con DNN (MinutizeNet), residual CNN. CoarseNet + FineNet.

Matching:

- \rightarrow reps: distorsiones no lineales por proyección; ponderamientos, interdependencia, calidad
- Minutize-based: alineamiento se produce en pares de minutas.
 - \rightarrow Global: transformaciones globales (Hough, RANSAC)
 - \rightarrow Local: local features pairing + consolidation step. (ej: k-dist, k-ratios).
- Ridge feature-based: Usar patrón de crestas (orientación, frecuencia, singularidades, ...). Gabor filter + euclidean distance.
- Correlation-based: se superponen los hellas y se calcula la correlación entre píxeles por distintos alineamientos.

Fingerprint Verification Competition (2000+)

Research Lines:

- Fake / altered fingerprint
- Double-Identities
- Latent

TEMA 4: IRIS

Iris: textura única y estable (a través de iris code)

J. Daugman \rightarrow National Geographic; iris code

Daugman blogos: Igual se fingerprint pero con iris code \leftrightarrow mismatches.

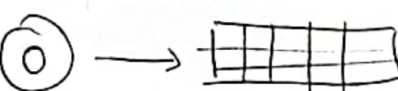
Sensores: ~~CCD~~ Near-Infrared, short distance

IRIS CODE

① Segmentación: encontrar las fronteras limbo (fuer) y pupilar.

\hookrightarrow Operador integral-diferencial de Daugman

\hookrightarrow BBox de la región ocular más grande

② Unwrapping:  fixed grid

\hookrightarrow Filtro Gabor 2D (código mismo tamaño) \rightarrow 2 bits / complex number

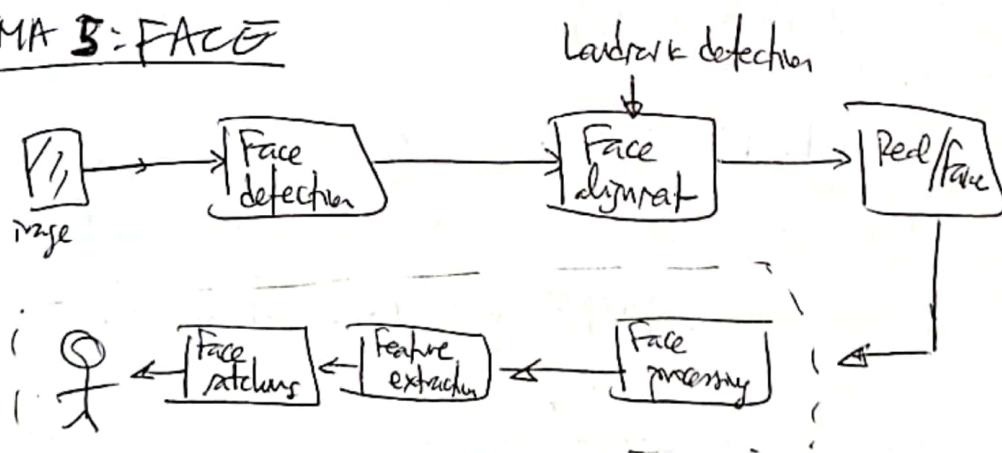
\hookrightarrow Máscara de occlusión

③ Code: 2048 bits: 8×128 rectangle (=1024 patches w/ 2 bits)

Matching: fractional Hamming distance: fraction of XORs that are 1 (fraction of bits that differ).

CNN: feature extraction; Iris PoseNet (autoencoder)

TEMA 3: FACE



Face detection (CNN)

- Region-based: proposals + classify whether they have a face (Fast/R-CNN)
- Sliding-window: bounding box + score at every location. Different scales (pyramid) ③

Almeauwerk

- Alinear mediante puntos de referencia (ojos, punta nariz, comisuras, ...)
- Detección de landmarks: deep learning (OpenFace2, HyperFace)

Presentation attack detection

- ↳ Texture-Based; depth-based (special sensors); physiological-based (video; heart-rate, eye blink, ...)

Face processing (learn invariant features)

Aumentar robustez vs pose, oclusión, iluminación, expresión, ...

- One-to-many augmentation: generar varias parches en distintas poses a partir de una sola imagen.
- Many-to-one normalization: recuperar vista canónica (frontal) de una o más imágenes no frontales.

Feature extraction: tres generalizaciones principales

- Métodos basados: PCA (eigenfaces) for reconstruction, and LDA (Fisherfaces) for discrimination: ↑ inter-class correlation and ↓ intra-class correlation. Insensitive to light or expression variation.

- Métodos lineales ⁽ⁱ⁾: Sparse matrix minimizing L1 norm (test image = sparse linear comb. of train images). Robust


(ii) Metric learning

- ↳ Aprender M métricas de minimizar la distancia entre inputs con labels similares, y maximizar la de los disímiles.
- ↳ Learn matrix to improve KNN: penalize large inter-class and small intra-class.
- ↳ Information-theoretic: Kullback-Leibler divergence.

• Métodos no lineales

Deep learning: acceso a grandes BDD. Usar CNNs ^{+ ejemplos} _{estructura} _{loss function}

- DeepFace, DeepId (smaller CNNs ensemble, with face patches), DeepId 2 (improve training process) → outperform human recognition (97.5% human), FaceNet (train using triplets of matching/non-matching face patches; using Inception modules), VGGNet (trained on smaller PDB3, competitive performance), ArcFace (improve loss function to maximize class separability), ResNet → best result, 99.83
- ResNet - shortcut connections (skip layers) to avoid degradation



Fairness


- FaceGenderId (reduce gender bias), SensitiveNet (remove sensitivity)
- GAN → generate representation of aged person?
- DeepFakes: images & video fakes pass any realstar.

TEMA 6: ESCRITURA

Letras:

- Gran variabilidad intra-usuario:
- Pequeña variabilidad inter-usuario: falsificaciones

Enfoques: offline (solo imagen), on-line (series temporales)
↳ device to capture



Devices:

- 100/200 samples/s (Nyquist)
- +1000 pixels/inch (ppp)

Signals

- \bar{x}, y, p
- Altitude (?)

Points equally distant in time.

Challenges - interoperability

- Different spatial position and/or time res.
- Lack of pressure (finger?)

Pre-processing

- Spatial normalization: size, position, rotation
- Time normalization: same sampling freq. (interpolate)

Feature Extraction

- Global features: multi-dimensional velocity vectors (duration, avg velocity, ...)
- Local features: set of time series (x-coord, pressure, speed, ...)

Similarity computation

① Global features - same length

- Distance-based classifiers: Euclidean (scale-dependent, curse of dim), Mahalanobis (problem: difficult to estimate Σ)
- Statistical/other classifiers: SVM, NN, ~~MLP, DNN, ...~~

② Local features


- Regional (segment-to-segment): Hidden Markov Models
- Local (point-to-point): Dynamic Time Warping
- New approach: deep-learning

↳ Siamese Arch. → learn dissimilarity metric.

↳ Recurrent NNs → LSTM (memory, learn parameters) { improve prev.

↳ Deep Sign database

↳ DTW + Deep learning: align time functions and feed to RNN

↳ align test sample and enrolled signature BEST  ^{enrolled} _{test}

Other research lines

- Coherent signatures (decompose strokes with lognormal velocity and sum) DNN
- Use signature complexity to train models (+ robust)